

GRUPO DE ESTUDO DE GERAÇÃO HIDRÁULICA - GGH

DIAGNÓSTICO DE DESALINHAMENTO E DESBALANCEAMENTO EM HIDROGERADORES UTILIZANDO MACHINE LEARNING (DEEP LEARNING)

YURI CROTTI(1);EMERSON LIMA DO NASCIMENTO(1);VITOR POHLENZ(1);TIAGO KAORU MATSUO(1);MARCOS HISASHI NAPOLI NISHIOKA(1);FABRICIO DE SOUZA BORGES(2) AQTECH ENGENHARIA E INSTRUMENTACAO S/A(1);SANTO ANTONIO ENERGIA SA(2)

RESUMO

A demanda no mercado de energia exige operações e manutenções eficientes em usinas hidrelétricas, evitando falhas que causem paralisações e prejuízos financeiros. A manutenção preditiva, baseada na análise de vibração, pode evitar avarias, mas requer dados rotulados dos modos de falha. Para superar a dificuldade de coletar dados em condições normais e de falha, um estudo propõe uma abordagem utilizando Deep Learning. Um modelo de aprendizado profundo é capaz de diagnosticar falhas de desalinhamento e desbalanceamento em hidrogeradores, analisando sinais de vibração e acústicos não rotulados. Os resultados mostram que o método é eficaz na detecção de anomalias e separação de problemas.

PALAVRAS-CHAVE

1.0 INTRODUÇÃO

A grande demanda no mercado de energia exige que a Operação e Manutenção (O&M) em usinas hidrelétricas muitas vezes ocorram em condições extremas, consequentemente, é comum a ocorrência de diversos tipos de falhas. Uma forma de aumentar a produtividade de uma usina hidrelétrica é garantir que ela esteja em pleno funcionamento. A ocorrência de falhas pode levar a paralisações e causar prejuízos financeiros à empresa que opera a usina. É, portanto, do interesse das empresas de energia encontrar uma forma de evitar este tipo de avarias e substituir a manutenção corretiva e preventiva pela manutenção preditiva.

De acordo com a ISO 13373-7 [1], os modos de falha de desbalanceamento e desalinhamento em unidades hidrelétricas apresentam sintomas típicos que se manifestam através da variação na magnitude dos componentes harmônicos da rotação da máquina. Portanto, monitorando a vibração da máquina é possível verificar se existem anomalias no espectro de vibração correlacionadas com esses modos de falha. Com a análise de vibração, informações valiosas podem ser obtidas sobre as condições de integridade do ativo.

O aprendizado de máquina (Deep Learning) faz parte de uma ampla família de métodos de aprendizagem baseado em representação de dados, e tem tido bastante sucesso em avançar seu estado da arte em várias áreas [2]. Porém, no setor elétrico ainda é embrionário o seu uso prático para diagnóstico de falhas.

Estudos que envolvem métodos de aprendizado supervisionados requerem dados rotulados dos modos de falhas que se deseja monitorar, ou seja, que as amostras de dados sejam previamente identificadas como saudáveis ou falhas para que os modelos sejam treinados. Como a maioria das usinas hidrelétricas opera de forma contínua e ininterrupta, não é trivial coletar dados em todas as condições da máquina, ou seja, condições normais e de falha.

Para contribuir para a solução desse problema, neste trabalho é proposto uma abordagem de aprendizado de máquina, mais precisamente em aprendizado profundo (Deep Learning). O modelo de aprendizado profundo proposto é capaz de capturar automaticamente as informações úteis dos sinais e detectar as anomalias e por fim agrupar falhas de desalinhamento e desbalanceamento em uma bancada de simulação.

2.0 METODOLOGIA

Nesta seção será apresentada a metodologia deste trabalho. Conforme ilustrado no diagrama da Figura 1 o funcionamento da metodologia proposta é dividido em quatro etapas: Experimentos e aquisição de dados, extração de

características, treinamento do modelo por aprendizado profundo, detecção de anomalia, agrupamento de falhas e avaliação dos resultados.




Figura 1 - Diagrama da metodologia proposta. Fonte: do autor.

2.1 EXPERIMENTOS E AQUISIÇÃO DE DADOS

Neste trabalho, utilizamos o banco de dados de uma bancada experimental de simulação de defeitos, como ilustrado na Figura 2. O objetivo principal era investigar o desempenho do módulo em diferentes configurações de velocidade, especificamente a 200, 300 e 500 RPM. Durante os testes, foram realizadas várias condições de operação, incluindo o funcionamento normal sem a presença de falhas, a introdução de desbalanceamentos por meio do volante e a criação de desalinhamentos por meio dos parafusos localizados nas laterais dos mancais.




Figura 2 - Bancada experimental de simulação de defeitos. Fonte: do autor.

Para simular desbalanceamentos, ajustamos o volante para introduzir massas adicionais em pontos específicos do sistema. Essas massas desequilibradas criaram forças centrífugas durante a rotação, resultando em vibrações indesejadas e impactando o desempenho geral do sistema. Essa configuração permitiu uma análise detalhada dos efeitos do desbalanceamento nas diferentes velocidades de rotação.

Além disso, para avaliar os efeitos do desalinhamento, foram realizados ajustes nos parafusos das laterais dos mancais, criando uma condição de desalinhamento angular. Essa configuração resultou em um desalinhamento entre as partes rotativas do sistema, levando a forças laterais e vibrações excessivas. Novamente, o desempenho do sistema foi analisado em cada uma das velocidades de rotação mencionadas.

Composto por 3 rolamentos, 3 acelerômetros foram fixados no primeiro mancal deslizante, 2 na direção radial a 0° e 90° e 1 axial. Além disso, foram utilizados 2 sensores de proximidade apontados para o eixo. Além da instrumentação do primeiro mancal, foram posicionados 2 acelerômetros no segundo e terceiro mancais no sentido radial a 0° e 90° , além de um microfone apontado para cada mancal.

2.2 EXTRAÇÃO DE CARACTERÍSTICAS

De acordo com [3], dado um grande conjunto inicial de variáveis físicas, o processo de extração de características consiste em gerar um novo conjunto de variáveis com melhor capacidade de discriminação e tamanho menor do que o conjunto inicial. Como apresentado em [4], a extração de características desempenha um papel muito importante no campo do processamento digital de sinais, uma vez que fornece uma representação numérica mais sucinta do

sinal à medida que ele é construído e, conseqüentemente, a caracterização dele no contexto de aprendizado de máquina se torna viável.

As características são extraídas em dois domínios: tempo e frequência, devido às informações contidas em ambos. Na Figura 3, são apresentadas as 34 características extraídas para cada sinal adquirido. Para cada amostra coletada, contendo 11 sensores, foram geradas um total de 374 características extraídas.




Figura 3 – Processo de extração de característica. Fonte: do autor.

2.3 DETECÇÃO DE ANOMALIAS – DEEP AUTOENCODER E AGRUPAMENTO

Detectar anomalias é uma tarefa crucial na implementação de modelos de aprendizado de máquina. A detecção de anomalias refere-se à identificação de padrões que não estão de acordo com o comportamento normal esperado [8]. A detecção de anomalias em modelos não supervisionados tenta encontrar anomalias nos dados sem usar qualquer tipo de rótulo.

Para desenvolver a abordagem proposta, utilizamos um autoencoder profundo (Deep Auto Encoder - DAE), que tem a tarefa de reconstruir/sintetizar os dados de entrada na saída. Um autoencoder profundo é composto por duas redes neurais artificiais simétricas, em que uma representa a codificação e a outra a decodificação.

A primeira rede, após o aprendizado, codifica as variáveis de entrada em um conjunto chamado espaço latente, com uma representação de menor dimensionalidade, o que força a rede a aprender as características mais relevantes dos dados de treinamento. Enquanto isso, a segunda rede decodifica/reconstrói as variáveis equivalentes sintetizadas. O aprendizado do conjunto de dados leva o autoencoder a reconstruir as variáveis de entrada, aproximando-as da distribuição de probabilidade do espaço de características [5].

A partir disso, o erro de reconstrução é usado como uma métrica para medir o grau de normalidade ou anomalia dos dados, pois são quantidades proporcionais. As anomalias são detectadas analisando o erro na reconstrução dos sinais de vibração, ou seja, a diferença entre os sinais adquiridos e aqueles reconstruídos pela rede neural.

O codificador pode ser representado pela equação 3 de codificação.

$$h = f(x) \quad (3)$$

Já o decodificador pode ser representado pela equação 4 de decodificação

$$r = g(h) \quad (4)$$

O autoencoder de forma geral pode ser descrito pela equação 5, onde você deseja r tão próximo quanto a entrada original x.

$$g(f(x)) = r \quad (5)$$

A Figura 4 apresenta a arquitetura do autoencoder profundo proposto neste trabalho.




Figura 4 – Estrutura do DeepAutoncoder.
Fonte: Adaptado pelo autor.

2.4 MÉTRICAS DE AVALIAÇÃO

Para avaliar a qualidade da abordagem proposta na detecção dos modelos, foram utilizadas métricas de avaliação como acurácia e precisão. Nesse conceito de classificação, temos algumas métricas que indicam os erros e acertos de um modelo, em relação ao resultado esperado.

- Verdadeiros Positivos (VP): classificação correta da classe positiva;
- Falsos Negativos (FN): erro em que o modelo previu a classe negativa quando o valor real era classe positiva;
- Falsos Positivos (FP): erro em que o modelo previu a classe positiva quando o valor real era a classe negativa;
- Verdadeiros Negativos (VN): classificação correta da classe negativa.

A Equação 1 apresenta como a métrica de acurácia é calculada, essa métrica indica um desempenho geral do modelo. Dentre todas as amostras, quantos o modelo classificou corretamente.

$$\text{Acurácia} = (VP + VN) / \text{Total de amostras} \quad (1)$$

A Equação 2 apresenta a métrica de precisão, essa métrica indica dentre todas as classificações da classe positiva que o modelo fez, quantas estão corretas

$$\text{Precisão} = (VP) / (VP + FP) \quad (2)$$

Outra ferramenta comumente utilizada para avaliação de modelos de machine learning é a matriz de confusão. A matriz de confusão (também conhecida como tabela de confusão) é uma tabela que mostra as previsões do modelo em relação às classes reais. Ela é geralmente usada para avaliar o desempenho de modelos de classificação. A matriz de confusão geralmente tem duas dimensões, conforme apresentado na Tabela I, onde as linhas representam as classes reais e as colunas representam as previsões do modelo.

TABELA I. EXEMPLO DE MATRIZ DE CONFUSÃO

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (VP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (VN)

3.0 RESULTADOS

O primeiro objetivo da abordagem proposta foi de detecção de dados normais e dados anômalos. Essa detecção se deu pelo erro de reconstrução dos sinais de entrada fornecido ao modelo deep autoencoder. Para uma melhor visualização destes sinais foram extraídas as informações espaço latente do deep autoencoder.

A Figura 5 mostra o espaço latente extraído, apresentando os valores reais para análise de valores normais, desalinhamento e desbalanceamento, bem como para análise de anomalia e dados normais. Também exibe as detecções feitas pelo modelo proposto neste trabalho




Figura 5 – Representação do espaço latente: valores reais e preditos.
Fonte: do autor.

Analisando os grupos formados pelo espaço latente do deep autoencoder apresentados na Figura 5 e a detecção das anomalias com base erro de reconstrução dos sinais, as métricas apresentadas na Tabela II mostram que a abordagem apresentou bons resultados para classificação de um dado normal e um dado anômalo, ou seja, desbalanceamento ou desalinhamento.

TABELA II. RESULTADOS DO MODELO PARA DADOS NORMAIS E ANÔMALOS

		Valor Predito	
		Normal	Anomalia
Real	Normal	19.74 %	0%
	Anomalia	0%	80.26 %

	Acurácia	Precisão
Normal	100%	100%
Anomalia		100%

A Figura 6 apresenta o agrupamento do espaço latente, tendo como objetivo classificar os dados anômalos dos modos de falhas.



Figura 6 – Representação do espaço latente: valores reais e preditos para desalinhamento e desbalanceamento.
Fonte: do autor.

Para uma avaliação da qualidade da abordagem proposta na classificação dos dados anômalos, foram utilizadas novamente as métricas para avaliação como acurácia e precisão. A Tabela III apresenta um resumo dos valores das métricas de qualidade da abordagem na classificação dos dados anômalos.

TABELA III. RESULTADOS DO MODELO PARA DADOS DE DESBALANCEAMENTO E DESALINHAMENTO

		Valor Predito			Acurácia	Precisão
		Desbalanceamento	Desalinhamento			
Real	Desbalanceamento	49.18%	5.74%	Desbalanceamento	93%	98%
	Desalinhamento	0.82%	44.26 %	Desalinhamento		89%

Analisando a Figura 6 em conjunto com a métricas apresentadas na Tabela III, pode-se observar que o espaço latente do deep autoencoder foi capaz de gerar grupos para os modos de falhas de desbalanceamento e desalinhamento e que foi possível classificar os modos de falhas com valores excelentes pelo ponto de vista das métricas de aprendizado de máquina.

Por fim, avaliou-se a capacidade de agrupamento dos níveis de severidade das falhas. Para cada problema, foram simulados dois níveis de falha: desbalanceamento com Nível 1 e Nível 2 de severidade, e desalinhamento com Nível 1 e Nível 2 de severidade.

A Figura 8 apresenta o agrupamento do espaço latente, tendo como objetivo classificar os níveis de severidade do modo de falha desalinhamento. A Tabela IV apresenta um resumo dos valores das métricas de qualidade da abordagem na classificação destas severidades.




Figura 8 – Representação do espaço latente: valores reais e preditos para níveis de desalinhamento.
Fonte: do autor.

TABELA IV. RESULTADOS DO MODELO PARA DADOS DE NÍVEIS DE DESALINHAMENTO

		Valor Predito			Acurácia	Precisão
		Nível 1	Nível 2			
Real	Nível 1	44.26%	6.56%	Nível 1	77%	73%
	Nível 2	16.39%	32.79 %	Nível 2		83%

O os resultados mostram que o modelo teve um desempenho aceitável na classificação dos níveis de desalinhamento. Para o Nível 1, o modelo previu corretamente 44.26% dos casos e erroneamente classificou 6.56% como Nível 2. Para o Nível 2, o modelo previu corretamente 32.79% dos casos e erroneamente classificou 16.39% como Nível 1 de desalinhamento. Em resumo o modelo obteve uma acurácia geral de 77% e 73% de previsão para o Nível 1 e 83% para Nível 2

A Figura 9 apresenta o agrupamento do espaço latente, tendo como objetivo classificar os níveis de severidade do modo de falha desalinhamento. A Tabela V apresenta um resumo dos valores das métricas de qualidade da abordagem na classificação destas severidades.



Figura 9 – Representação do espaço latente: valores reais e preditos para níveis de desbalanceamento.
Fonte: do autor.

TABELA V. RESULTADOS DO MODELO PARA DADOS DE NÍVEIS DE DESBALANCEAMENTO

		Valor Predito			Acurácia	Precisão
		Nível 1	Nível 2			
Real	Nível 1	44.26%	6.56%	Nível 1	70%	66%
	Nível 2	22.95%	26.23%	Nível 2		80%

Os resultados mostram que o modelo teve um desempenho aceitável na classificação dos níveis de desbalanceamento. Para o Nível 1, o modelo previu corretamente 44.26% dos casos e erroneamente classificou 6.56% como Nível 2. Para o Nível 2, o modelo previu corretamente 22.95% dos casos e erroneamente classificou 26.23% como Nível 1. Em resumo o modelo obteve uma acurácia geral de 70% e 66% de previsão para o Nível 1 e 80% para Nível 2 para o desbalanceamento.

4.0 CONCLUSÃO

Os resultados obtidos confirmam a eficácia da abordagem proposta, que se baseia em aprendizado profundo, na detecção de anomalias utilizando o erro de reconstrução do deep autoencoder em dados de vibração e acústica em uma bancada de simulação.

Além disso, a abordagem demonstrou a capacidade de agrupar e detectar problemas relacionados ao desalinhamento e desbalanceamento. Isso indica que o uso de aprendizado profundo com autoencoder tem um

grande potencial para auxiliar no diagnóstico em unidades hidrelétricas. Essa abordagem promissora contribui para a manutenção preditiva no setor elétrico brasileiro.

Outro ponto importante é a alta precisão na detecção dos níveis de cada um dos modos de falha, o que evidencia a confiabilidade e a assertividade da abordagem.

5.0 AGRADECIMENTOS

Este trabalho é parte integrante do projeto de P&D ANEEL PD-06683-0220/2020 intitulado “Sistema de Aprendizado de Máquina (Machine Learning) para análise e diagnóstico de falhas em hidroelétricas com base em dados de processo, vibração e acústica”. Agradecemos a contribuição da equipe da Santo Antônio Energia em viabilizar este projeto de pesquisa.

REFERÊNCIAS

- (1) INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. ISO 13373-2- Condition monitoring and diagnostics of machines — Vibration condition monitoring. P. 8,2016.
- (2) ZHOU, Chong; PAFFENROTH, Randy C. Anomaly detection with robust deep autoencoders. In: Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining. 2017. p. 665-674., pp. 665–674.
- (3) Cardoso, João Francisco de Sousa. "Predição da qualidade na indústria de fundição injectada." (2001).
- (4) Rao, Preeti. "Audio signal processing." Speech, Audio, Image and Biomedical Signal Processing using Neural Networks. Springer, Berlin, Heidelberg, 2008. 169-189.
- (5) Goodfellow, Ian, Yoshua Bengio, and Aaron Courville. Deep learning. MIT press, 2016.

DADOS BIOGRÁFICOS

(1) YURI CROTTI
Yuri Crotti nasceu em Lauro Muller/SC em 1994. É mestre em Tecnologia da Informação e Comunicação (2020) e graduado em Engenharia da Computação (2018), ambos pela Universidade Federal de Santa Catarina. Desde 2012 trabalha em projetos envolvendo inteligência artificial, visão computacional (computer vision), aprendizado de máquina (machine learning) e ferramentas para monitoramento e controle de ambientes nos setores energético e industrial. Atualmente é Cientista de Dados e Desenvolvedor de Machine Learning na AQTech Power Prognostics de Florianópolis

(2) EMERSON LIMA DO NASCIMENTO
Nasceu em Pesqueira/PE em 1996. É bacharel em engenharia eletrônica pela Universidade Federal de Pernambuco e mestrando em engenharia elétrica pela mesma universidade, onde estuda IA e processamento digital de sinais. Atualmente é Líder da Central de Análise da Condição (CAC) na AQTech Power Prognostics e atua com monitoramento da condição de turbinas eólicas e hidráulicas e ciência dos dados.

(3) VITOR POHLENZ
Vitor Pohlenz nasceu em Caçador/SC em 1996. Formado em Engenharia Elétrica e atualmente cursando mestrado em ciência de dados e machine learning na Universidade Federal de Santa Catarina (UFSC). Durante sua carreira trabalhou com análise de dados para criação e modelagem de índices, inferência estatística, tratamento de banco de dados, people analytics, e desenvolvimento de modelos de machine learning para diversas aplicações. Utiliza principalmente as linguagens de programação Python e R, aplicando conhecimentos de probabilidade e estatística no setor elétrico. Atualmente é Cientista de Dados na AQTech Power Prognostics desenvolvendo soluções baseadas nas tecnologias Python, R e seus frameworks.

(4) TIAGO KAORU MATSUO
Tiago Kaoru Matsuo nasceu em Florianópolis/SC em 1986. É mestre em Mecatrônica pelo IFSC (2017), formado em Engenharia elétrica pela UFSC (2010) e técnico em eletrônica (CEFET-SC, 2005). Trabalha desde 2006 no desenvolvimento de tecnologias para monitoramento e diagnóstico de máquinas rotativas, principalmente no setor elétrico. Atualmente é Diretor de Técnico na AQTech Power Prognostics, sediada em Florianópolis.

(5) MARCOS HISASHI NAPOLI NISHIOKA
Graduado em engenharia mecânica pela Universidade Federal de Santa Catarina (UFSC, 2018). Bolsista pelo Laboratório de Engenharia Biomecânica (LEBm/HU-UFSC) de 05/2015 a 05/2017 em análise de materiais e ensaios mecânicos. Consultor de projetos para i9 Consultoria, Empresa Junior de 07/2016 a 12/2017. Estagiário de engenharia pela empresa Wier, Tecnologia em Plasma e Ozônio de 06/2017 a 11/2017. Líder de desenvolvimento de produtos para o mercado eólica pela AQTech. É analista de vibrações ISO nível IV. Pós-graduando em nível Mestrado na UFSC, área de Vibrações e Acústica.

(6) FABRICIO DE SOUZA BORGES
Fabrício de Souza Borges nasceu em Ipatinga/MG em 1989. Possui Graduação em Engenharia Elétrica pela Universidade Federal de Minas Gerais (2013), e MBA em Gerenciamento de Projetos pela Fundação Getúlio Vargas (2016). Tem experiência na área de Distribuição e Geração de Energia Elétrica. Trabalha atualmente na Santo Antônio Energia, onde desde 2020 atua na área de Manutenção de Unidades Geradoras.