

GRUPO DE ESTUDO DE OPERAÇÃO DE SISTEMAS ELÉTRICOS - GOP

DESENVOLVIMENTO DE FERRAMENTA BASEADA EM REDES NEURAIS ARTIFICIAIS PARA APLICAÇÃO AO PROBLEMA DA PREVISÃO DE VAZÕES

FABIO GODOY FERREIRA(1);RODRIGO AZAMBUJA(2);RICARDO CANELOI DOS SANTOS(3);PATRICIA TEIXEIRA LEITE ASANO
BOLT ENERGY COMERCIALIZADORA DE ENERGIA LTDA.(1);CAMARA DE COMERCIALIZACAO DE ENERGIA ELETRICA(2);FUNDAÇÃO UNIVERSIDADE FEDERAL DO ABC(3)

RESUMO


Apesar da expansão das fontes intermitentes, o parque hidrotérmico brasileiro continuará relevante. Logo, continuará necessária a projeção de variáveis como a vazão natural afluyente (VNA), que determina a geração hidráulica, térmica e o custo marginal da operação. A VNA é calculada por modelos físicos e estatísticos, que possuem limitações metodológicas. Este trabalho propõe duas alternativas a esses modelos, sendo que ambas usam metodologias de aprendizado de máquina. A primeira é baseada na metodologia de Time Delay Neural Network TDNN), e a segunda é baseada na metodologia de Long Short Term Memory LSTM). Nos testes realizados, as metodologias propostas obtiveram resultados superiores aos das metodologias atuais.

PALAVRAS-CHAVE. Previsão de vazões, aprendizado de máquina, redes neurais artificiais, planejamento energético.

1.0 INTRODUÇÃO

Segundo dados do (ONS, 2023) e da (EPE, 2023), as fontes com maior participação na matriz de energia elétrica brasileira são a térmica e a hidráulica, que representam 73,65%, e as projeções indicam que essas fontes continuarão a ser predominantes até 2027, quando as duas fontes representarão 68,1% de toda a matriz (Figura 1). Desse modo, apesar da queda de cerca de 5%, o sistema elétrico brasileiro continuará a ser predominantemente hidrotérmico.

Figura 1 - Matriz de energia elétrica brasileira em 2023 e 2027 (elaborado pelo autor)




A Figura 1 também mostra que a capacidade instalada da fonte hidráulica não terá nenhuma expansão significativa, enquanto as demais fontes, com exceção de nuclear, continuarão a aumentar sua participação na matriz com destaque para as fontes eólica, solar e mini e microgeração distribuída (MMGD). Então, o Brasil caminha para uma matriz cada vez mais dependente de fontes intermitentes (eólica, solar e MMGD) e térmica, e menos dependente da hidráulica.

No entanto, a diminuição da participação da fonte hidráulica implica que não serão construídas novas usinas com reservatório de acumulação, que atuam como as baterias do Sistema Interligado Nacional (SIN). Isto mostra que a capacidade de armazenamento de energia do SIN não está sendo preparada para atuar em um sistema com maior

participação de fontes intermitentes. A Figura 2 mostra o nível de armazenamento do SIN nos últimos 10 anos (ONS, 2023).


Figura 2 - Histórico de armazenamento do SIN no período 2012 a 2023 (elaborado pelo autor)



Como pode ser visto na Figura 2, no ano de 2023, o nível dos reservatórios atingiu um valor que não era visto desde 2011. Ainda assim, não há garantia de que o nível permanecerá neste patamar (vide os anos subsequentes a 2012), portanto o gerenciamento dos reservatórios continuará a ser de extrema importância para a operação segura do SIN.

Atualmente, parte do gerenciamento dos reservatórios é feito na etapa de programação quando o Operador Nacional do Sistema Elétrico (ONS) utiliza uma cadeia de modelos computacionais (Figura 3) para otimizar a operação do sistema, e atender a demanda atual e futura com o menor custo possível.

Figura 3 - Modelos computacionais do setor elétrico brasileiro (elaborado pelo autor)




Como mostra a Figura 3, a otimização da operação do sistema depende do processo destacado pelo retângulo vermelho, que engloba os modelos de previsão de vazões (SMAP, PREVIVAZ e CPINS) e de geração de cenários hidrológicos (GEVAZP). Esses modelos são necessários, porque a vazão é uma variável de grande incerteza por ser resultado de um processo hidrológico, que é intrinsecamente estocástico. E, de acordo com (Naghttini e Pinto, 2007), processos estocásticos só podem ser descritos pelas leis da probabilidade, o que justifica a combinação de previsão de vazões com geração de cenários.

Outro ponto importante mostrado pela Figura 3, é que os resultados dos modelos de previsão e geração de cenários são dados de entrada dos modelos NEWAVE, DECOMP e DESSEM. Isto significa que além de impactar a operação do SIN, os modelos hidrológicos também impactam o cálculo do Preço de Liquidação das Diferenças (PLD) publicado diariamente pela Câmara de Comercialização de Energia Elétrica (CCEE).


Em (CCEE, 2017), o impacto de cada variável na formação do PLD foi analisado e o resultado pode ser visto na Figura 4. Neste trabalho, a variável de medida foi a volatilidade, ou seja, qual a contribuição de cada variável para a volatilidade do PLD.

Figura 4 - Impacto de cada variável na volatilidade do PLD (CCEE, 2017)



Como exposto na Figura 4, a hidrologia é a variável que mais impacta a volatilidade do PLD. Isto evidencia a importância dos modelos hidrológicos destacados na Figura 3, e como é importante que eles tenham resultados que se aproximem da realidade. No entanto, como mostra a Figura 5 (ONS, 2020), a proximidade com a realidade do processo de previsão de vazões perde muito de sua acurácia conforme se expande o horizonte de previsão. Consequentemente, esses desvios entre previsto e realizado são incorporados pelos modelos de formação de preço.

Figura 5 - Comparação entre vazão observada e prevista em 2019



2.0 OBJETIVO

A fim de melhorar a etapa de previsão de vazões, propõe-se duas metodologias em linguagem *open source*, sendo que uma delas aplica a arquitetura de uma rede neural artificial (RNA) com algoritmo de aprendizado *backpropagation*, e a outra utiliza uma arquitetura de rede neural recorrente (RNR) do tipo *Long Short Term Memory* (LSTM) com algoritmo de otimização *Adaptive Moment Estimation* (Adam).

A metodologia da RNA será aplicada a previsão de vazões mensais das usinas hidrelétricas de Furnas, Mascarenhas de Moraes e Marimbondo, e a metodologia da LSTM será aplicada a previsão de vazões diária dos postos de medição das bacias do rio Doce, Paranaíba e Grande.

3.0 METODOLOGIA


3.1 Redes Neurais Artificiais

Estruturalmente, as RNAs possuem os neurônios como as unidades mais básicas de toda a sua arquitetura. Estes neurônios podem ser organizados em três tipos de camadas: entrada, intermediária(s) e saída. Outro componente importante das RNAs são as conexões existentes entre cada neurônio. Essas conexões possuem pesos, que são chamados de pesos sinápticos, e que são atualizados pelo algoritmo de aprendizado. Desse modo, conexões mais relevantes são atualizadas positivamente, enquanto as menos relevantes são atualizadas negativamente (Silva et al., 2010).

A quantidade de neurônios em cada camada, assim como o número de camadas, são parâmetros variáveis de uma RNA. Aos parâmetros da RNA que podem sofrer alterações é dado o nome de hiperparâmetro. No presente trabalho, tanto o número de neurônios quanto o número de camadas serão variados até encontrar quais são os valores que geram os melhores resultados de acordo com o critério de parada do algoritmo (número de iterações ou minimização de uma função de erro) (Haykin, 2009).

Neste trabalho, as RNAs foram utilizadas para prever de valores a partir das séries históricas de vazões mensais de hidrelétricas. Segundo (Bishop, 1995), é possível extrair um conjunto de valores como x_{t-2} , x_{t-1} , ..., x_t de uma série histórica, e apresentá-los como dados de entrada à rede para prever o valor x_{t+1} (Figura 6).

Figura 6 - Dados de entrada x_{t-2} , x_{t-1} e x_t da rede neural *feedforward* e o dado a ser previsto x_{t+1} (Adaptado de Bishop, 1995)



No caso do estudo da previsão de vazões das usinas hidrelétricas, cada valor x_{t+1} é incorporado ao conjunto de dados como se fosse um valor realizado em um método de janela deslizante (Figura 7).

Figura 7 - Janela deslizante empregada


		MESES											...	n
		1	2	3	4	5	6	7	8	9	10	11		
Iterações	x_1	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}	x_{11}	...	x_n
	x_1		x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}	x_{11}	...	x_n
	x_1			x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}	x_{11}	...	x_n
	x_1		x_2		x_4	x_5	x_6	x_7	x_8	x_9	x_{10}	x_{11}	...	x_n
	x_1			x_3		x_5	x_6	x_7	x_8	x_9	x_{10}	x_{11}	...	x_n
	x_1		x_2		x_4		x_6	x_7	x_8	x_9	x_{10}	x_{11}	...	x_n
	x_1			x_3			x_6	x_7	x_8	x_9	x_{10}	x_{11}	...	x_n

Então, partindo da hipótese que vazões passadas têm impacto no resultado de vazões futuras, 12 meses foram utilizados como dado de entrada para prever a vazão do próximo mês da série histórica, simulando o comportamento de um modelo autorregressivo de ordem 12. O processo foi repetido até completar a janela de previsão escolhida para cada usina, que também foi testada até se obter o melhor resultado. A princípio, o objetivo era realizar a previsão de vazões 60 meses a frente para que fosse algo compatível com o modelo NEWAVE.

Do conjunto de dados utilizado, o treinamento da rede foi feito utilizando 75% dos dados do período de 1933 a 1994 (excluindo os anos de 1972 a 1976), e os 25% restantes foi utilizado na etapa de validação. Para a etapa de teste foram utilizados os dados do período de 2010 a 2015.

O algoritmo de aprendizado empregado foi o *backpropagation*, que tem o objetivo de minimizar o erro quadrático calculado entre os valores de vazão observado e previsto. A Figura 8 ilustra a variação do erro quadrático em função das matrizes de pesos sinápticos.

Figura 8 - Exemplo de uma função de erro quadrático



Dois termos importantes para este algoritmo de aprendizado são o termo *momentum* e a taxa de aprendizado. Estes foram variados até encontrar um par que obtivesse um resultado que fosse ao menos equivalente aos resultados obtidos através dos modelos atualmente utilizados pelo ONS.

Como mencionado nos Objetivos, a RNA e o algoritmo de aprendizado foram desenvolvidos na linguagem *open source* Java.

3.2 Long Short Term Memory

Diferente da metodologia da RNA, a LSTM é uma rede neural recorrente, porque é uma das arquiteturas mais indicadas para processar séries históricas, principalmente quando é necessário que a RNR consiga identificar relações de curto e longo prazo.

Dada essa propriedade da LSTM, e considerando as características do problema de previsão de vazões, (Kratzert et al., 2018) desenvolveram um pacote na linguagem de programação *Python*, e que foi batizado de *Neural Hydrology*, com o objetivo principal de utilizar dados de variáveis dinâmicas e estáticas das bacias hidrográficas para realizar a previsão de vazões. Então, a primeira diferença entre as duas metodologias é que a metodologia da LSTM não foi desenvolvida, logo trata-se da aplicação de uma ferramenta desenvolvida pelos autores citados.

O *Neural Hydrology* foi desenvolvido com base na modelagem chuva-vazão, ou seja, ele é semelhante ao modelo *Soil Moisture Accounting Procedure* (SMAP) desenvolvido e utilizado pelo ONS. Diferente do SMAP, o *Neural Hydrology* utiliza uma grande base de dados de postos de medição de variáveis hidrológicas, meteorológicas, geológicas, entre outras. Estas variáveis foram acessadas através da base de dados *Catchment Attributes and Meteorology for Large-sample Studies – Brazil* (CAMELS-BR) coletada e publicamente disponibilizada por (Chagas et al., 2020).

O CAMELS-BR reúne séries históricas de vazões com granularidade diária para 3679 medidores (dados “crus” sem nenhum processamento). (Chagas et al., 2020) analisaram os dados desses 3679 medidores, e compilaram as variáveis de forçantes meteorológicas (temperatura, umidade, precipitação, entre outros), topográficas, climáticas, hidrológicas, cobertura de área, geológicas, solo e intervenção humana para 897 áreas de captação. Para a LSTM, este grande conjunto de dados foi dividido da seguinte maneira:

- Período de treinamento: de 1º de outubro de 2006 a 30 de setembro de 2016;
- Período de validação: de 1º de outubro de 1987 a 30 de setembro de 1996;
- Período de teste: de 1º de outubro de 1996 a 30 de setembro de 2006;

Por fim, vale citar que outra diferença entre o *Neural Hydrology* e o SMAP é que a calibração do modelo é feita durante o processo de aprendizado da LSTM, isto é, a calibração não é manual.

4.0 RESULTADOS E DISCUSSÕES

4.1 Redes Neurais Artificiais

Como mencionado anteriormente, uma das hipóteses da RNA desenvolvida era de que a previsão de vazão seria realizada sempre utilizando dados de 12 meses para prever a vazão de um mês seguinte qualquer. Com isso, já ficou definido que a camada de entrada teria 12 neurônios.

Para o número de neurônios da camada intermediária, em geral, quanto maior o número de neurônios na camada intermediária, maior a probabilidade de ocorrência de *overfitting*, que é quando a RNA “memoriza” quais devem ser as saídas ao invés de “aprender” os padrões a partir do conjunto de dados, e como não há uma metodologia que determine com exatidão o número de neurônios da camada, neste trabalho, concluiu-se que o número de 24 a 25 neurônios era o suficiente para evitar o *overfitting*.

Com relação aos demais parâmetros de treinamento como taxa de aprendizado e termo momentum foram feitos testes com diversos valores, e os que obtiveram melhores resultados foram as taxas de aprendizado η igual a 0,2 e 0,26 e termos momentum α igual a 0,03, 0,05 e 0,1.

Usina	Neurônios (E-I-S)	Taxa de aprendizado (η)	Momentum (α)	Épocas	MAPE (%)
Furnas	12-25-1	0,26	0,1	92	28,72
	12-24-1	0,2	0,03	152	25,64
	12-24-1	0,2	0,05	117	26,68
	12-25-1	0,2	0,03	93	25,47
Mascarenhas de Moraes	12-24-1	0,09	0,05	130	45,70
	12-25-1	0,09	0,05	125	42,29
	12-26-1	0,09	0,05	98	34,79
Marimbondo	12-24-1	0,09	0,05	217	33,37
	12-25-1	0,09	0,05	203	27,37
	12-26-1	0,09	0,05	114	26,52

Tabela 1 - Resultados obtidos com a RNA

Ao longo dos experimentos, constatou-se que o algoritmo de aprendizado implementado não produzia bons resultados se não se utilizasse valores de taxa de aprendizado e momentum pequenos. Segundo (Bishop, 1995), estes dois parâmetros impactam o tempo computacional. No entanto, é possível ver que pelo número de épocas que isto não teve impacto negativo/impeditivo na execução do estudo.

Por fim, ao comparar com os resultados obtidos pelo SMAP (ONS, 2020), e expostos na Tabela 2, observa-se que para o caso da usina de Furnas, o MAPE obtido com a RNA é comparável ao obtido com a metodologia atual no horizonte de 3 semanas a frente.

Nos casos das usinas Mascarenhas de Moraes e Marimbondo, o MAPE da metodologia atual é inferior ao calculado através da metodologia de RNA proposta, no entanto cabe destacar que o horizonte de previsão da RNA é muito superior (60 meses) em comparação ao horizonte da metodologia atual (até 3 semanas), o que confirma a hipótese de que um modelo de RNA gera resultados melhores do que a metodologia atualmente empregada.

Usina	1ª semana	2ª semana	3ª semana
Furnas	13%	21%	26%
Mascarenhas de Moraes	12%	19%	23%
Marimbondo	10%	15%	20%

Tabela 2 - MAPE obtido com a metodologia atual

4.2 Long Short Term Memory

Os experimentos foram realizados para as bacias do rio Doce, Paranaíba e Grande. Nos três casos, foram testadas diferentes combinações das variáveis disponíveis no CAMELS-BR. A avaliação dos resultados foi feita a partir do cálculo do coeficiente de Nash-Sutcliffe (NSE) obtidos foram:

NSE	Doce	Paranaíba	Grande
Mínimo	0,2737	0,2703	0,1100
Máximo	0,8872	0,8417	0,8652
Média	0,7353	0,6051	0,6888
Desvio-padrão	0,1214	0,1490	0,1585

Tabela 3 - Coeficiente de Nash-Sutcliffe calculado para cada bacia

Devido ao grande volume de dados, a obtenção dos resultados destes experimentos durou cerca de 2 horas para cada execução. Ao se considerar que foram feitas diversas execuções até se obter os resultados expostos na Tabela 3, conclui-se que, apesar de dispensar o ajuste manual dos parâmetros, a tarefa é computacionalmente intensiva, e exige um bom *hardware*.

Para estas mesmas bacias, o (ONS, 2020) obteve os seguintes resultados de NSE:

Bacia	1ª semana	2ª semana	3ª semana
Doce	0,19	0,22	0,29
Paranaíba	0,85	0,70	0,58
Grande	0,88	0,68	0,64

Tabela 4 - Resultados de NSE obtidos para cada bacia a partir do modelo SMAP

Assim como mostrado na Tabela 2 para o MAPE, o valor do NSE diminui conforme se aumenta o horizonte de previsão. Também vale destacar que o resultado obtido pelo modelo SMAP para a bacia do Rio Doce é muito inferior ao resultado obtido pela LSTM (Tabela 3). Para a bacia do Rio Paranaíba, o resultado obtido pela LSTM passa a ser superior quando se considera o horizonte de 3 semanas de previsão do SMAP. Para a bacia do Rio Grande, o resultado obtido pela LSTM passa a ser superior já a partir do momento em que o horizonte de previsão é maior ou igual a 2 semanas.

Por fim, destaca-se a facilidade de utilização do *Neural Hydrology*, e do potencial e diversos usos que possui o algoritmo.

5.0 CONCLUSÃO

As duas propostas apresentadas foram implementadas com sucesso, sendo que a proposta da RNA foi toda desenvolvida e implementada na linguagem *Java*, ao passo que a LSTM foi desenvolvida por (Kratzert et al., 2018) em *Python*, e aplicada para o caso brasileiro a partir do conjunto de dados CAMELS-BR.

Como mencionado, cada um dos modelos utilizou conjuntos de dados diferentes, a RNA utilizou apenas a série histórica de vazões mensais para fazer as previsões, e a LSTM utilizou um conjunto de variáveis meteorológicas, climáticas, geológicas, topográficas, entre outras para realizar a previsão da mesma variável.

A partir da análise dos resultados, conclui-se que ambas as metodologias possuem viabilidade para serem aplicadas ao problema de previsão de vazões, e que os resultados obtidos por ambas as propostas foram superiores aos obtidos pelas ferramentas tradicionais utilizadas pelo ONS, porque ambas as metodologias fazem a previsão para uma janela de previsão superior à dos modelos utilizados oficialmente.

Outra importante conclusão é a de que a ausência de uma modelagem física, lembrando que as propostas estudadas são do tipo *data-driven*, dos processos hidrológicos não prejudicou os resultados de nenhuma das propostas.

6.0 REFERÊNCIA BIBLIOGRÁFICA

BISHOP, C. M. **Neural networks for pattern recognition**. [S.l.]: Oxford University Press, 1995.

Câmara de Comercialização de Energia Elétrica. Perspectivas para Aprimoramento da Formação de Preços no Brasil. **IV Simpósio Nacional de Regulação, Economia e Mercados de Energia Elétrica**, 2017.

CHAGAS, V. B. P.; CHAFFE, P. L. B.; ADDOR, N.; FAN, F. M.; FLEISCHMANN, A. S.; PAIVA, R. C. D.; SIQUEIRA, V. A. CAMELS-BR: hydrometeorological time series and landscape attributes for 897 catchments in Brazil. *Earth Syst. Sci. Data*, 12, p. 2075–2096, Disponível em: <<https://doi.org/10.5194/essd-12-2075-2020>>, 2020.

EMPRESA DE PESQUISA ENERGÉTICA. Painel de Dados de Micro e Minigeração Distribuída. Rio de Janeiro: Empresa de Pesquisa Energética, 2023.

HAYKIN, S. **Neural Networks and Learning Machines**. [S.l.]: Prentice Hall, 2009.

KRATZERT, F.; KLOTZ, D.; BRENNER, C.; SCHULZ, K.; HERRNEGGER, M. Rainfall–runoff modelling using long short-term memory (lstm) networks. *Hydrology and Earth System Sciences*, 22(11):6005–6022, 2018.

NAGHETTINI, M.; PINTO, E. J. A. **Hidrologia estatística**. [S.l.]: CPRM, 2007. 552 p. ISBN 9788574990231.

ONS. **Histórico da Operação:** energia armazenada máxima. Energia Armazenada. 2023. Disponível em: http://www.ons.org.br/Paginas/resultados-da-operacao/historico-da-operacao/energia_armazenada.aspx. Acesso em: 1º julho 2023.

SILVA, I. N.; FLAUZINO, R. A.; SPATTI, D. H. **Redes Neurais Artificiais para engenharia e ciências aplicadas**. [S.I.]: Artliber Editora Ltda, 2010.

DADOS BIOGRÁFICOS

(1) **FABIO GODOY FERREIRA**
 Graduado em Engenharia de Energia (2016) pela Universidade Federal do ABC (UFABC) e mestre em Energia (2022) pela mesma instituição, atuo com os modelos de precificação de energia desde 2018, quando iniciei minha carreira na Câmara de Comercialização de Energia Elétrica (CCEE). Desde 2022, atuo como analista de preços sênior na comercializadora de energia Bolt Energy, onde contribuo com projeção de preços e as demais variáveis. Minha área de interesse é inteligência artificial aplicada ao problema de previsão de vazões.

(2) **PATRICIA TEIXEIRA LEITE ASANO**
 graduação em Engenharia Elétrica pela Universidade Federal de Mato Grosso (1995), mestrado na Escola de Engenharia de São Carlos de Universidade de São Paulo (1999) e doutorado em Engenharia Elétrica na Escola de Engenharia de São Carlos da Universidade de São Paulo (2003). Atualmente é professora Associada da Universidade Federal do ABC (UFABC). Tem experiência na área de Engenharia Elétrica e de Energia, com ênfase em Planejamento da Operação de Sistemas Hidrotérmicos de Potência, atuando principalmente nos seguintes temas: planejamento da operação de sistema hidrotérmicos de potência, geração distribuída, comercialização de energia elétrica, otimização, suas aplicações adotando Técnicas Inteligência Artificial

(3) **RODRIGO AZAMBUJA**
 Bacharel em Meteorologia pela Universidade Federal de Santa Maria (UFSM), mestre e doutor em Geofísica Espacial (2017) pelo Instituto Nacional de Pesquisas Espaciais (INPE). Atua na área de Modelos e Estudos Energéticos, com foco na hidrometeorologia, energias renováveis e carga aplicadas aos modelos de formação de preço. Atualmente é Especialista de Modelos e Estudos Energéticos na Câmara de Comercialização de Energia Elétrica (CCEE).

(4) **RICARDO CANELOI DOS SANTOS**
 Graduação em Engenharia Industrial Elétrica pela Universidade Santa Cecília (1996), mestrado em Engenharia Elétrica pela Universidade de São Paulo (2000), doutorado em Engenharia Elétrica pela Universidade de São Paulo (2004) e pós-doutorado pela University of Bath (United Kingdom, 2014). Atualmente é Professor Titular da Universidade Federal do ABC. Tem experiência na área de Engenharia Elétrica, com ênfase em Medição, Controle, Correção e Proteção de Sistemas Elétricos de Potência. Possui interesse principalmente nos seguintes temas: proteção e confiabilidade de sistemas elétricos (HVAC e HVDC), algoritmos inteligentes para detecção e localização de faltas, redes neurais artificiais e redes elétricas inteligentes.